


Analisis Clustering dan Klasifikasi Penderita Diabetes

Marcella Aurelia Yatijan - 71477




Tujuan

Menerapkan algoritma K-Means Clustering dan KNN Classification untuk mengeksplorasi segmentasi pasien dan melakukan prediksi berdasarkan hasil klaster.

Membandingkan label asli (Outcome) dengan label hasil klastering untuk melihat sejauh mana pola yang ditemukan oleh algoritma sesuai dengan kenyataan medis.

Menganalisis hasil K-Means Clustering berdasarkan sifat data setiap cluster



Data Pasien

Dataset: Pima Indians Diabetes 768 pasien

Target

Outcome (0 = tidak diabetes, 1 = diabetes)

Features

01 Pregnancies

02 Glucose

03 Blood Pressure

04 Skin Thickness

05 Insulin

06 Body Mass Index

07 Diabetes Pedigree Function

08 Age



Pemilihan Fitur

Menurut medis

Faktor yang sangat mempengaruhi

1. Glucose → Kadar glukosa puasa tinggi adalah indikator utama untuk mendiagnosis diabetes tipe 2.
2. BMI → BMI tinggi, Risiko tinggi
3. Age → Risiko diabetes meningkat secara signifikan setelah usia 45 tahun.
4. DiabetesPedigreeFunction → Faktor Genetik

Faktor yang juga dapat mempengaruhi

1. Insulin → Bisa berpengaruh, tapi sulit diinterpretasi tanpa tahu waktu pengukuran. Nilai insulin yang sangat tinggi bisa menandakan resistensi insulin.
2. Pregnancies → relevan untuk wanita

Faktor yang juga dapat mempengaruhi

1. SkinThickness (Ketebalan lipatan kulit triceps) → kurang akurat dibanding BMI
2. BloodPressure → Hipertensi sering menyertai diabetes, tapi bukan indikator langsung. Kadang lebih relevan untuk prediksi komplikasi daripada diagnosis awal.






Pemilihan Fitur

Dengan T-Test

Fitur	P-Value	Signifikan?	Penjelasan
Pregnancies	0.0000	✓ Ya	Jumlah kehamilan beda signifikan antara yang diabetes dan tidak.
Glucose	0.0000	✓ Ya	Glukosa sangat berpengaruh terhadap outcome diabetes.
BloodPressure	0.0887	✗ Tidak	Tidak beda signifikan antar kelompok ($p > 0.05$).
SkinThickness	0.0544	✗ Tidak	Tidak beda signifikan antar kelompok ($p > 0.05$).
Insulin	0.0002	✓ Ya	Sangat signifikan.
BMI	0.0000	✓ Ya	Sangat signifikan — obesitas terkait kuat dengan diabetes.
DiabetesPedigreeFunction	0.0000	✓ Ya	Faktor genetik signifikan terhadap outcome.
Age	0.0000	✓ Ya	Usia lebih tua punya kemungkinan diabetes lebih tinggi.



Pemilihan Fitur

Dengan Random Forest




Clustering With K-Means

Determining the number of Cluster




Clustering dengan K-Means


2 Cluster



Distribusi Outcome Asli



Distribusi Hasil Klastering




Clustering dengan K-Means

2 Cluster


- ✅ Cluster 0 – Low Risk – 15% Diabetes
- ⚠️ Cluster 1 – High Risk – 62% Diabetes

Fitur	Cluster 0	Cluster 1
Glucose (Gula darah)	103.4 (rendah)	145.4 (tinggi)
BMI	29.5 (normal/tinggi)	35.5 (obesitas)
Age (Usia)	27.6 (muda)	41.1 (dewasa/tua)
Diabetes Pedigree Function	0.4	0.57

Klasifikasi dengan KNN




Confusion Matrix - KNN vs Label Hasil KMeans



✓ Accuracy: 96%

● ROC AUC (Label dari KMeans) : 0.9960

Confusion Matrix - KNN vs Label Dataset Outcome



✓ Accuracy: 77%

● ROC AUC (Label dari Outcome) : 0.8187

Klasifikasi dengan KNN



Label dari KMeans

- ✓ Accuracy: 96%
- ROC AUC : 0.9960

KMeans → **unsupervised learning**
Membuat label berdasarkan kemiripan fitur

"Tanpa tahu kenyataan medis siapa yang benar-benar diabetes."

Jadi label hasil KMeans seringkali **lebih "bersih" dan konsisten** secara pola fitur

Label Datasets

- ✓ Accuracy: 77%
- ROC AUC: 0.8187

Label Outcome di dataset ini berasal dari data medis asli yang **tidak selalu bersih.**

Ada faktor:

- ! Orang dengan Glukosa normal tapi ternyata diabetes
- ! Pasien muda yang sudah diabetes
- ! Noise / data error / ketidaksempurnaan diagnosis
- ! Pengaruh fitur yang tidak disediakan (misalnya HbA1c, genetik, lifestyle)

Akibatnya, pola **tidak selalu bisa dipisahkan secara sederhana**, dan KNN kesulitan meniru keputusan itu → akurasi turun.



Kesimpulan 1



💡 **Stratifikasi Risiko Otomatis**

- Bahkan tanpa label “diabetes” dari dokter, sistem bisa membantu menyaring pasien ke dua grup: berisiko vs tidak berisiko.

◆ **Cluster 0 → Pasien Risiko Rendah / Sehat**

- Ciri-ciri: kadar gula dan BMI normal, usia muda, riwayat keluarga lemah.
- Artinya: pasien ini *belum menunjukkan gejala signifikan* terkait diabetes.

◆ **Cluster 1 → Pasien Risiko Tinggi / Potensi Diabetes**

- Ciri-ciri: kadar gula tinggi, BMI obesitas, usia lanjut, kemungkinan ada riwayat keluarga.
- Artinya: pasien ini berisiko tinggi, dan perlu **pemeriksaan lanjut atau intervensi preventif**.


👜 **Implementasi**

- **Asuransi** → Decision support penentuan premi
- **Klinik/RS**
- → edukasi gizi, prioritas layanan, atau pengingat follow-up untuk cluster berisiko tinggi
- → alokasi sumber daya dan menyusun program pencegahan khusus (misalnya edukasi nutrisi untuk cluster berisiko tinggi).




Clustering dengan K-Means


3 Cluster



Distribusi Outcome Asli



Distribusi Hasil Klastering (k=3)



Validasi Hasil Clustering Dengan KNN


3 Cluster

Classification Report:

	precision	recall	f1-score	support
0	0.95	0.99	0.97	73
1	0.95	0.92	0.93	38
2	0.98	0.93	0.95	43
accuracy			0.95	154
macro avg	0.96	0.95	0.95	154
weighted avg	0.95	0.95	0.95	154

Akurasi KNN tinggi menandakan bahwa hasil clustering Konsisten.

Pola antar data dalam feature space (misalnya Glucose, BMI, dll) cukup konsisten dan terpisah jelas antar cluster.



KNN Bisa Memprediksi Cluster sehingga apabila ada data baru, KNN bisa memetakan dia masuk ke cluster mana dengan cukup akurat berdasarkan fitur.

Clustering dengan K-Means

3 Cluster

Cluster 0

Fitur	Nilai Rata-rata	Catatan
Glucose: 103.03	Rendah (normal)	Glukosa mendekati normal — kemungkinan sehat
BMI: 29.22	Hampir obesitas	Tapi masih di bawah rata-rata cluster lain
DiabetesPedigree: 0.34	Rendah riwayat keturunan	Risiko keturunan rendah
Age: 26.4	Umur muda	Umumnya lebih muda dari cluster lain

✅ Interpretasi:

Cluster 0 berisi orang muda, glukosa normal, tidak terlalu gemuk, dan risiko keturunan rendah → kemungkinan besar kelompok sehat.

Cluster 1

Fitur	Nilai Rata-rata	Catatan
Glucose: 136.94	Tinggi	Glukosa sangat tinggi (di atas 126 sudah diabetes)
BMI: 37.03	Obesitas	Obesitas kelas 2 → risiko tinggi
DiabetesPedigree: 0.84	Sangat tinggi	Ada keturunan kuat diabetes
Age: 30.98	Dewasa muda	Tapi lebih muda dari cluster 2

⚠️ Interpretasi:

Cluster 1 adalah kelompok risiko tinggi — obesitas, kadar glukosa tinggi, dan faktor genetik kuat.
Kemungkinan besar **banyak penderita diabetes** di sini.

Cluster 2

Fitur	Nilai Rata-rata	Catatan
Glucose: 138.35	Sangat tinggi	Lebih tinggi dari cluster 1 bahkan
BMI: 32.23	Obesitas ringan	Masih cukup tinggi
DiabetesPedigree: 0.36	Rendah	Risiko keturunan rendah
Age: 48.06	Tertua dari semua	Umur menengah ke atas → usia risiko

⚠️ Interpretasi:

Cluster 2 = orang tua, glukosa sangat tinggi, BMI tinggi, tapi tidak banyak faktor keturunan.
Kemungkinan kelompok **penderita diabetes** karena faktor gaya hidup atau usia.

Kesimpulan 2

Kesimpulan

Cluster	Profil Umum	Kelas
0	Muda, sehat, glukosa normal, tidak obesitas	Sehat
1	Glukosa tinggi, obesitas parah, keturunan kuat	Diabetes karena genetik + gaya hidup
2	Glukosa sangat tinggi, tua, BMI tinggi	Diabetes karena usia dan gaya hidup

Kelas yang dihasilkan oleh clustering cukup menarik



Saran

- Validasi hasil clustering dengan data klinis riil.
- Perlu menambahkan fitur agar model lebih representatif dan akurat dengan medis.
- Dapat melakukan eksplorasi jumlah cluster

